

3 תרגיל | IML (67577)

שם: יואב שפירא | ת"ז: 312492838

28 באפריל 2022

חלק תאורטי

1. תחילה נשים לב ש

$$\arg \min_w \|w\|^2 = \arg \min_w \left(\frac{1}{2} \|w\|^2 \right)$$

ולכן אתייחס מעתה לבעיה עם הכפילה בחצי. לבעיות מינימיזציה עם אילוצים ניתן להגדיר את הלגראנז'אן ולפתור בעזרתו. במגרה זה האילוץ הוא "א"ש, ולכן נצטרך להתייחס אליו מאוחר יותר כדי לדאוג שהוא נשמר. נגדיר:

$$L(w, b, \bar{\lambda}) = \frac{1}{2} \|w\|^2 + \sum_i \lambda_i (y_i w_i x_i + y_i b - 1)$$

כאשר $\bar{\lambda} = \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_n \end{pmatrix}$ כופלי לגראנז'. כעת הבעיה המקורית שקולה לבעיה של חישוב $\arg \min_{w, b, a} (L(w, b, \bar{\lambda}))$. נפרש את הביטוי:

$$\begin{aligned} L(w, b, \bar{\lambda}) &= \frac{1}{2} \|w\|^2 + \sum_i \lambda_i (y_i w_i x_i + y_i b - 1) \\ &= \frac{1}{2} w^T w + \sum_i \lambda_i y_i w_i x_i + \sum_i \lambda_i y_i b - \sum_i \lambda_i \end{aligned}$$

נבחין כי w האופטימלי לבעיה זו מקיים:

$$\arg \min_w (L(w, b, \bar{\lambda})) = \arg \min_w \left(\frac{1}{2} w^T w + \sum_i \lambda_i y_i w_i x_i \right)$$

כלומר החלקים שאינם תלויים ב- w לא משנים את הפיתרון. לכן נוכל להגדיר:

$$v = w, \quad Q = I, \quad a = \sum \lambda_i y_i x_i \in \mathbb{R}^n$$

ונקבל שהבעיה שאנחנו רוצים לפתור היא:

$$\arg \min_v \frac{1}{2} v^T Q v + a^T v$$

נשים לב לאילוצים: האילוך המקורי הוא (בפישוט):

$$\begin{aligned} \forall_i : y_i w_i x_i + y_i b &\geq 1 \\ \iff -y_i x_i w_i &\leq 1 - y_i b \\ \iff (-X^T \bar{y}) w &\leq 1 - \bar{y} b \end{aligned}$$

ועל כן נגדיר:

$$A = -X^T \bar{y}, \quad d = 1 - \bar{y} b$$

ונקבל שהאילוך החדש הוא $Av \leq d$. חשוב להדגיש, שבגלל צורת הפיתרון שנובעת מהלגרנז'יאן, יש לנו גם אילוך על \bar{h} : הוא חייב להיות אי שלילי. כלומר לכל i צ"ל $\lambda_i \geq 0$. זוהי עדיין QP : בעיית אופטימיזציה ריבועית תחת אילוצים ליניאריים.

2. בעצם צ"ל ש:

$$\xi_i = \ell^h(y_i \langle w, x_i \rangle) \iff \xi_i \geq 0 \wedge y_i \langle w, x_i \rangle \geq 1 - \xi_i$$

\implies נניח כי $\xi_i \geq 0 \wedge y_i \langle w, x_i \rangle \geq 1 - \xi_i$. אז:

$$\ell^h(y_i \langle w, x_i \rangle) = \max \{0, 1 - y_i \langle w, x_i \rangle\}$$

נשים לב כי מתקיים מההנחה ש:

$$1 - y_i \langle w, x_i \rangle \leq 1 - (1 - \xi_i) = \xi_i$$

וכמו כן מההנחה ש $\xi_i \geq 0$ ולכן $\ell^h(y_i \langle w, x_i \rangle) = \xi_i$

\Longleftarrow נניח כי $\xi_i = \ell^h(y_i \langle w, x_i \rangle)$. אז זה אומר ש

$$\max \{0, 1 - y_i \langle w, x_i \rangle\} = \xi_i$$

כלומר בכל מקרה $\xi_i \geq 0$ וגם $1 - y_i \langle w, x_i \rangle = \xi_i$, ובפרט מתקיים ש $y_i \langle w, x_i \rangle \geq 1 - \xi_i$.

3. נעשה פה ניתוח של מעריך בייסיאני גאוסיאני בצורה דומה לניתוח שנעשה בתרגול עם LDA , כשנשים לב לשוני המהותי בין השניים: LDA הוא ליניארי, ומניח כי כל המחלקות שניתן לסווג אליהן מתפלגות עם אותה שונות רק עם תוחלת שונה. המעריך הגאוסיאני בייסיאני לא מניח שונות שווה, אלא מניח שכל המחלקות מתפלגות נורמלית עם תוחלת ושונות אחרים, ובנוסף מניח אי-תלות של הפיצורים בדאטא (וכאן הוא שונה מ- QDA). זה יהיה ההבדל בסעיף (ב): כתוצאה מכך יוצא מעריך לא ליניארי, שבנוסף מעריך סטיית תקן לכל אחת מהמחלקות. בגלל אי התלות יוצא שלכל מחלקה יש קווריאנס אלכסוני (כי כל הפיצורים בת"ל).

(א) לפיתוח:

נפתח את הביטוי שעליו צריך למצוא $argMax$:

$$\phi(\Theta|X, Y) = f_{X,Y|\Theta}(\{X_i, y_i\}_{i=1}^m)$$

כלומר למצוא פרמטרים להתפלגויות הנתונות, כך שימקסמו את הביטוי הנ"ל. נסמן ב- k את המחלקות האפשריות של y_i , כלומר $\mathbb{P}(y_i = k) = \pi_k = \pi_{y_i}$. נפתח:

$$\begin{aligned}\phi(\Theta|X, Y) &= f_{X,Y|\Theta}(\{X_i, y_i\}_{i=1}^m) \\ i.i.d &= \prod_{i=1}^m (f_{X_i, y_i=k|\Theta}(X_i, k)) \\ &= \prod_{i=1}^m (f_{X_i|y_i=k}(X_i) \cdot f_{y_i=k|\Theta}(k)) \\ &= \prod_{i=1}^m (\mathcal{N}(\mu_{y_i}, \sigma_{y_i}) \cdot \pi_{y_i})\end{aligned}$$

כשהמעבר האחרון מההתפלגויות הנתונות לנו. ניקח לוגריתם:

$$\begin{aligned}\log(\phi(\Theta|X, Y)) &= \log \prod_{i=1}^m (\mathcal{N}(\mu_{y_i}, \sigma_{y_i}) \cdot \pi_{y_i}) \\ &= \sum_{i=1}^m \log(\mathcal{N}(\mu_{y_i}, \sigma_{y_i}) \cdot \pi_{y_i}) \\ &= \sum_{i=1}^m \log \left(\frac{1}{\sqrt{2\pi\sigma_{y_i}^2}} \cdot \exp \left(-\frac{(x_i - \mu_{y_i})^2}{2\sigma_{y_i}^2} \right) \cdot \pi_{y_i} \right) \\ \log rules &= \sum_{i=1}^m \log(\pi_{y_i}) - \log \left(\sqrt{2\pi\sigma_{y_i}^2} \right) - \frac{(x_i - \mu_{y_i})^2}{2\sigma_{y_i}^2} \\ more &= \sum_{i=1}^m \log(\pi_{y_i}) - \frac{1}{2} \log(\sigma_{y_i}^2) - \frac{1}{2} \log(2\pi) - \frac{(x_i - \mu_{y_i})^2}{2\sigma_{y_i}^2}\end{aligned}$$

בצורה דומה לנעשה בתרגול, נסמן ב- n_k את מספר המופעים של הלייבל k בדאטא, כלומר $n_k = \sum_{i=1}^m \mathbb{I}_{[y_i=k]}$. ככה ניתן לרשום את הביטוי למעלה כ:

$$\log(\phi(\Theta|X, Y)) = \sum_k n_k \log(\pi_k) - \frac{1}{2} \sum_i \frac{\mathbb{I}_{[y_i=k]} (x_i - \mu_k)^2}{\sigma_k^2} - \sum_k \frac{n_k}{2} \log(\sigma_k^2)$$

את הביטוי הזה צריך למקסם לפי הפרמטרים. בנוסף יש אילוץ על π_k : $\sum_k \pi_k = 1$. נרכיב לגראנז'יאן לביטוי:

$$\mathcal{L}(\hat{\pi}, \hat{\mu}, \hat{\sigma}, \lambda) = \log(\phi(\Theta|X, Y)) - \lambda \left(\sum_k \pi_k - 1 \right)$$

נגזור תחילה לפי π ונקבל:

$$\frac{\partial \mathcal{L}}{\partial \pi_k} = \frac{\partial \log(\phi(\Theta|X, Y))}{\partial \pi_k} - \lambda \cdot \frac{\partial \mathcal{L}}{\partial \pi_k} = \frac{n_k}{\pi_k} - \lambda$$

נשווה ל 0 ונקבל

$$\hat{\pi}_k = \frac{n_k}{\lambda}$$

מהתנאי ש $\sum_k \pi_k = 1$ נקבל כי $\lambda = m$.

הפרמטר μ מביא את אותו ביטוי שראינו בתרגול (רק הפעם חד מימדי, יותר פשוט) ולכן נקבל

$$\hat{\mu}_k = \frac{1}{n_k} \sum \mathbb{I}_{[y_i=k]} x_i \in \mathbb{R}$$

כלומר התוחלת של כל הדגימות שהלייבל שלהם הוא k . זוהי תוצאה לתוצאה שקיבלנו ב LDA. עבור σ אנחנו מקבלים הפעם ביטוי קצת שונה בגלל ההנחות השונות: במקום שונות אחת משותפת לכל הלייבלים כמו ב LDA, אנחנו רוצים לבטא את השונות של כל לייבל בנפרד. כלומר:

$$\hat{\sigma}_k^2 = \frac{1}{n_k} \sum \mathbb{I}_{[y_i=k]} (x_i - \hat{\mu}_k)^2 \in \mathbb{R}$$

(ב) כעת נרחיב ל d פיצ'רים של הדאטא, ונסמן $\bar{x}_i \in \mathbb{R}^d$ דגימה מהדאטא. נחזור ל $likelihood$ (לוג) מסעיף קודם ונחיל את הנוסחה של גאוסיאן רב מימדי:

$$\begin{aligned} \log(\phi(\Theta|X, Y)) &= \log \prod_{i=1}^m (\mathcal{N}(\bar{\mu}_{y_i}, \Sigma_{y_i}) \cdot \pi_{y_i}) \\ &= \sum_{i=1}^m \log(\mathcal{N}(\bar{\mu}_{y_i}, \Sigma_{y_i}) \cdot \pi_{y_i}) \\ &= \sum_{i=1}^m \log \left(\frac{1}{\sqrt{(2\pi)^d |\Sigma_{y_i}|}} \cdot \exp \left(-\frac{1}{2} (x_i - \bar{\mu}_{y_i})^T \Sigma_{y_i}^{-1} (x_i - \bar{\mu}_{y_i}) \right) \cdot \pi_{y_i} \right) \\ \log \text{ rules} &= \sum_{i=1}^m \log(\pi_{y_i}) - \log \left(\sqrt{(2\pi)^d |\Sigma_{y_i}|} \right) - \frac{1}{2} (x_i - \bar{\mu}_{y_i})^T \Sigma_{y_i}^{-1} (x_i - \bar{\mu}_{y_i}) \\ \text{more} &= \sum_{i=1}^m \log(\pi_{y_i}) - \frac{d}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma_{y_i}|) - \frac{1}{2} (x_i - \bar{\mu}_{y_i})^T \Sigma_{y_i}^{-1} (x_i - \bar{\mu}_{y_i}) \end{aligned}$$

נרצה למקסם את הביטוי, ונבחין כי $-\frac{d}{2} \log(2\pi)$ הוא קבוע ולכן נתעלם ממנו בשלב זה. באותה צורה כמו בחד מימדי, נשתמש באינדיקטורים כדי לרשום את הנוסחה בצורה קצת שונה:

$$\log(\phi(\Theta|X, Y)) = \sum_k n_k \log(\pi_k) - \frac{1}{2} \log(|\Sigma_k|) - \frac{1}{2} \sum_i \mathbb{I}_{[y_i=k]} (x_i - \bar{\mu}_k)^T \Sigma_k^{-1} (x_i - \bar{\mu}_k)$$

נרכיב לגראנז'יאן שיכלול את האילוי על π_k :

$$\mathcal{L}(\hat{\pi}, \hat{\mu}, \hat{\Sigma}, \lambda) = \log(\phi(\Theta|X, Y)) - \lambda \left(\sum_k \pi_k - 1 \right)$$

ניתן לראות בקלות שגזירת לפי π_k נותנת בדיוק את אותה תוצאה:

$$\hat{\pi}_k = \frac{n_k}{m}$$

הגזירה לפי $\overline{\mu_k}$ זהה לגזירה שראינו בתרגול הפעם. נקבל:

$$\hat{\mu}_k = \frac{1}{n_k} \sum \mathbb{I}_{[y_i=k]} \bar{x}_i \in \mathbb{R}^d$$

ולמעשה סיימנו השונות מוגדרת ע"י ההנחה של האומד, והיא שונות אחרת לכל k וגם פיצ'רים בת"ל. תחת ההנחה שכל הפיצ'רים הם בת"ל, המטריצת שונות תהיה אלכסונית, (בגודל d על d) - אם כל הפיצ'רים הם בת"ל, אז אין ביניהם קורלציה, וכל האיברים מחוץ לאלכסון שווים ל-0. לכן נוכל פשוט לבטא את השונות של לייבל k ע"י לקיחת כל האיברים על האלכסון והרכבת וקטור עם d כניסות. כלומר נגדיר:

$$\hat{\sigma}_k^2 = \text{Diag} \left(\sum \mathbb{I}_{[y_i=k]} (x_i - \hat{\mu}_k) (x_i - \hat{\mu}_k)^T \right)$$

ובסופו של דבר לצורך המימוש בקוד, נרכיב מטריצת שונויות שתבוטא כך:

$$Vars = \begin{bmatrix} \hat{\sigma}_1^2 \\ \vdots \\ \hat{\sigma}_k^2 \end{bmatrix} \in \mathbb{R}^{k \times d}$$

4.

(א) פואסון חד מימדי: נתון כי

$$f_y(k) = \pi_k, f_{x_i|y_i}(x_i) = \frac{\lambda_{y_i}^{-x_i} \cdot e^{-\lambda_{y_i}}}{x_i!}$$

והאילוי הרגיל על $\sum_k \pi_k = 1$. צריך למקסם את הביטוי:

$$\begin{aligned} \phi(\Theta|X, Y) &= f_{X,Y|\Theta}(\{X_i, y_i\}_{i=1}^m) \\ i.i.d &= \prod_{i=1}^m (f_{x_i, y_i|\Theta}(x_i, y_i)) \\ &= \prod_{i=1}^m (f_{x_i|y_i}(x_i) \cdot f_{y_i}(y_i)) \\ &= \prod_{i=1}^m \left(\frac{\lambda_{y_i}^{-x_i} \cdot e^{-\lambda_{y_i}}}{x_i!} \cdot \pi_{y_i} \right) \end{aligned}$$

צריך למקסם אז אפשר לקחת לוגריתם:

$$\begin{aligned} \log(\phi(\Theta|X, Y)) &= \sum_i^m \log\left(\frac{\lambda_{y_i}^{x_i} \cdot e^{-\lambda_{y_i}}}{x_i!} \cdot \pi_{y_i}\right) \\ &= \sum_i^m [\log(\lambda_{y_i}^{x_i}) + \log(e^{-\lambda_{y_i}}) + \log(\pi_{y_i}) - \log(x_i!)] \\ &= -\sum_i^m \log(x_i!) + \sum_i^m [x_i \log(\lambda_{y_i}) - \lambda_{y_i} + \log(\pi_{y_i})] \end{aligned}$$

נבחין כי הביטוי הראשון הוא קבוע ולכן נשמיט אותו מכאן. נשתמש באינדיקטורים כדי לספור מופעים על $y_i = k$, ונכתוב את הביטוי כך:

$$\log(\phi(\Theta|X, Y)) = \sum_i^m \mathbb{I}_{[y_i=k]} \cdot x_i \log(\lambda_{y_i}) - n_k \lambda_k + n_k \log(\pi_k)$$

נרכיב את הלגראנז'יאן:

$$\mathcal{L}(\hat{\pi}, \hat{\lambda}, \tau) = \log(\phi(\Theta|X, Y)) - \tau \left(\sum_k \pi_k - 1 \right)$$

למנוע בלבול: כאן τ הם כופלי לגראנז'. נגזור לפי π_k :

$$\frac{\partial \mathcal{L}}{\partial \pi_k} = \frac{n_k}{\pi_k} - \tau$$

נקבל את אותה תוצאה כמו בשאלה 3:

$$\hat{\pi}_k = \frac{n_k}{m}$$

נגזור לפי λ_k :

$$\frac{\partial \mathcal{L}}{\partial \lambda_k} = -n_k + \sum_i^m \mathbb{I}_{[y_i=k]} \cdot x_i \log(\lambda_{y_i}) \stackrel{!}{=} 0$$

נקבל ש:

$$\lambda_k = \frac{\sum_i^m \mathbb{I}_{[y_i=k]} \cdot x_i}{n_k}$$

כלומר פשוט התוחלת של כל הסאמפלים שהלייבל שלהם הוא k .

(ב) פואסון רב מימדי: כעת $f_{x_i|y_i}(x_i) = \prod_{j=1}^d \frac{\lambda_{y_i,j}^{x_{ij}} \cdot e^{-\lambda_{y_i,j}}}{x_{ij}!}$ כלומר לכל \bar{x}_i יש d פיצ'רים שכולם מתפלגים פואסון עם פרמטר $\lambda_{y_i,j}$ באופן בת"ל. נפתח את הלוג-לייקליהוד:

$$\begin{aligned}\phi(\Theta|X, Y) &= f_{X,Y|\Theta}(\{X_i, y_i\}_{i=1}^m) \\ i.i.d &= \prod_{i=1}^m (f_{x_i,y_i|\Theta}(x_i, y_i)) \\ &= \prod_{i=1}^m (f_{x_i|y_i}(x_i) \cdot f_{y_i}(y_i)) \\ &= \prod_{i=1}^m \left(\prod_{j=1}^d \frac{\lambda_{y_i,j}^{x_{ij}} \cdot e^{-\lambda_{y_i,j}}}{x_{ij}!} \cdot \pi_{y_i} \right)\end{aligned}$$

ניקח לוג:

$$\begin{aligned}\log(\phi(\Theta|X, Y)) &= \sum_i \log \left(\prod_{j=1}^d \frac{\lambda_{y_i,j}^{x_{ij}} \cdot e^{-\lambda_{y_i,j}}}{x_{ij}!} \cdot \pi_{y_i} \right) \\ &= \sum_i \sum_j \left[\log(\lambda_{y_i,j}^{x_{ij}}) + \log(e^{-\lambda_{y_i,j}}) + \log(\pi_{y_i}) - \log(x_{ij}!) \right] \\ &= - \sum_i \sum_j \log(x_{ij}!) + \sum_i \sum_j [x_{ij} \log(\lambda_{y_i,j}) - \lambda_{y_i,j} + \log(\pi_{y_i})]\end{aligned}$$

הראשון קבוע ויושמט, ועכשיו נשתמש בטריק האינדיקטור:

$$= \sum_k \sum_j \left[\sum_i \mathbb{I}_{[y_i=k]} x_{ij} \log(\lambda_{y_i,j}) + n_k (\log(\pi_k) - \lambda_{k,j}) \right]$$

נרכיב לגראנז'יאן כמו מקודם (\mathcal{L} הביטוי ו τ הכופלים) ונגזור לפי π_k ונקבל:

$$\frac{\partial \mathcal{L}}{\partial \pi_k} = \frac{dn_k}{\pi_k} - \tau \stackrel{!}{=} 0 \implies \pi_k = \frac{dn_k}{\tau}$$

מכך ש $\sum_k \pi_k = 1$ נקבל ש

$$\sum_k \frac{dn_k}{\tau} = 1 \implies \tau = md$$

ומכאן נקבל בסהכ כי $\hat{\pi}_k = \frac{n_k}{m}$ באופן מאוד לא מפתיע.

נגזור לפי $\lambda_{k,j}$:

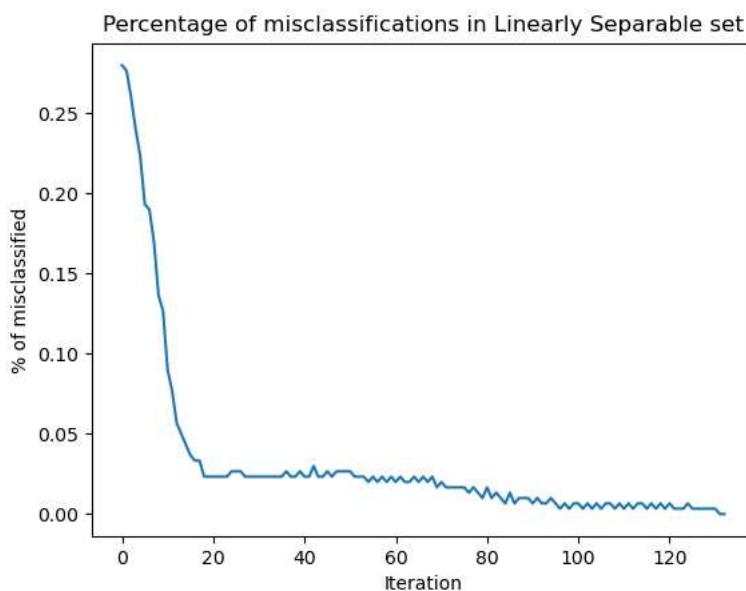
$$\frac{\partial \mathcal{L}}{\partial \lambda_{k,j}} = -n_k + \sum_i \mathbb{I}_{[y_i=k]} x_{ij} \log(\lambda_{y_i,j})$$

בדיוק כמו בסעיף החד מימדי. נקבל ש $\hat{\lambda}_{k,j} = \frac{\sum_i \mathbb{I}_{[y_i=k]} x_{ij}}{n_k}$ התוחלת של הפיצ'ר j בתוך כל הסאמפלים שהלייבל שלהם הוא k .

חלק פרקטי

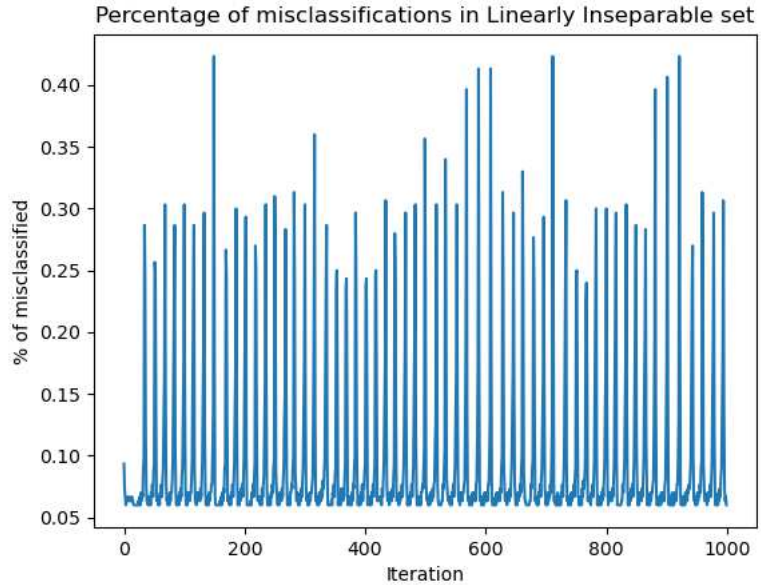
Perceptron classifier

1. הגרף הבא מציג את אחוז השגיאות, כלומר *Misclassification*, עבור הדאטא שניתן להפרדה ליניארית כפונקציית *Fit* של האיטרציות בפונקציית הפרספטרון:



ניתן לראות שלא הגענו למקסימום איטרציות, כלומר הגענו למצב שבו כל הקלסיפיקציות נכונות - מצאנו מישור שמפריד ליניארית את הדאטא.

2. הגרף הבא מציג את אותה הפונקציית אך עבור הדאטא שאינו ניתן להפרדה:



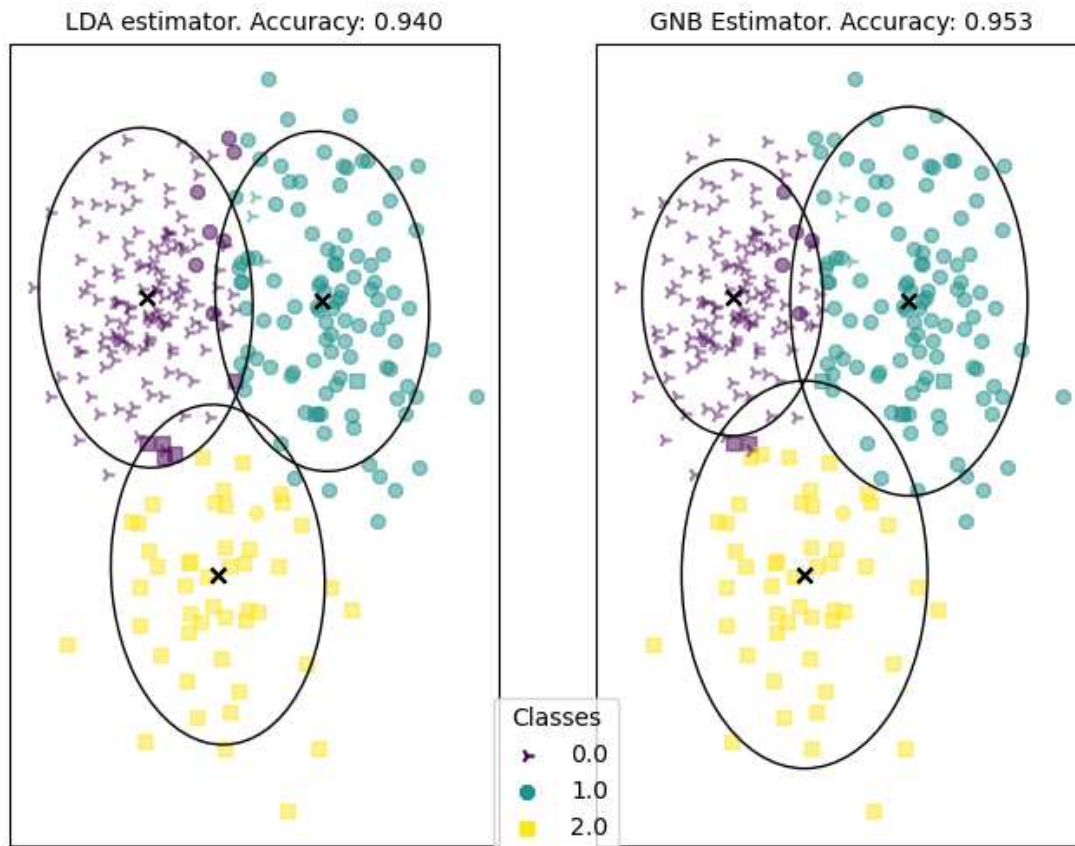
הגרף מתנהג בצורה משוגעת כי אנחנו מחפשים מישור שיהיה 'צודק' לגבי כל הנקודות בדאטא, ומכיוון שזה דאטא שאי אפשר להפריד ליניארית זה מצב לא אפשרי. זו גם הסיבה שהגענו למקסימום איטרציות שאפשרנו. אם היינו 'מתפשרים' על $Soft - SVM$ כלומר על מישור שנותן מרווח טעות, אך מינימלית - היה אפשר להוציא תוצאה די טובה, בערך 0.06% טעות, המינימום שמופיע בגרף. רוב הדאטא בעולם הוא לא ניתן להפרדה ליניארית או לפחות לא ידוע לנו עליו שכן, והתעקשות על $Hard - SVM$ הרבה פעמים תביא תוצאות לא כל כך טובות כמו זו.

Bayes classifiers

בגרפים הבאים לכל מחלקה ניתן צבע וצורה המופיעים במקרא. נקודה על הגרף שאיננה תואמת למקרא, משמעותה טעות בסיווג.

1. הגרף הבא מציג ריצה של LDA ושל GNB על דאטא ללא קורלציה, או קורלציה חלשה, בין הפיצ'רים:

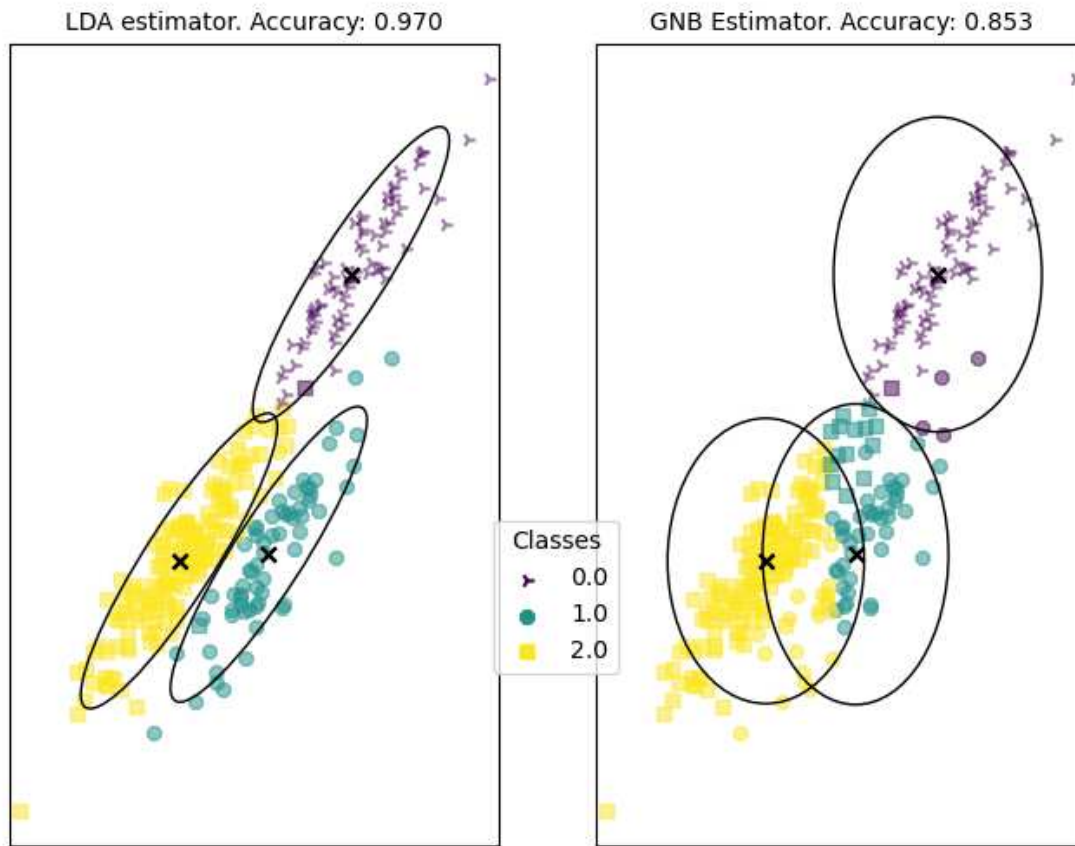
Dataset: gaussian1.npy



ניתן לראות שעבור GNB הצליח יותר בחיזוי שלו, ולכן ניתן להניח שהדאטא מקיים (או כמעט מקיים) את ההנחות שלו: מכיוון שהוא מניח דאטא שמגיע מהתפלגויות שונות (גאוסיאנים, אבל פרמטרים שונים), ניתן לומר שההתפלגות שממנה נדגם הדאטא באמת מתנהגת כך: לכל לייבל יש התפלגות שונה. כמו כן GNB מניח אי תלות בין הפיצ'רים של הדאטא, שאת זה ניתן לראות בעיניים שמתקיים כאן, ולכן הוא זכה להצלחה גדולה. אף על פי כן, מכך שה LDA הלינארי הצליח גם לא רע יחסית, אפשר ללמוד שבין כל התפלגות של שני לייבלים, אפשר למצוא איזשהו מישור מפריד שיהיה יחסית מוצלח (ואכן אפשר לראות בעיניים שזה המצב).

2. הגרף הבא מציג ריצה של LDA ושל GNB על דאטא עם קורלציה חיובית חזקה בין הפיצ'רים:

Dataset: gaussian2.npy



ה LDA מוצלח יותר מה GNB .

מכיוון שההצלחה של LDA גבוהה, ניתן ללמוד שהדאטא מקיים (או כמעט מקיים) את ההנחות שלו: כל הלייבלים מתפלגים בצורה זהה (כלומר זהים בשונות) אך עם תוחלת אחרת. ההנחה של GNB שהדאטא מקיים אי־תלות בין הפיצ'רים לא נכונה כאן, ורואים שאחוזי ההצלחה שלו נמוכים בהרבה, לעומת LDA שפשוט לא מניח כלום לגבי תלות בין הפיצ'רים. כמו כן LDA הוא ליניארי, ואכן אפשר לראות שניתן למתוח מישורים מפרידים בין כל שני לייבלים שיצליחו להפריד בין שניהם בצורה טובה.